

1. 问题重述与目标

我们想证明：分块计算得到的输出 O 与一次性计算标准Attention的 O 在数学上完全相等。

标准Softmax Attention公式（对于第 i 个查询向量）：

令 $s_{ij} = Q_i K_j^T / \sqrt{d}$ 为原始分数。

设：

$$m_i = \max_{1 \leq k \leq N} s_{ik}$$

$$f_{ij} = \exp(s_{ij} - m_i)$$

$$\ell_i = \sum_{k=1}^N f_{ik}$$

$$P_{ij} = \frac{f_{ij}}{\ell_i}$$

$$O_i = \sum_{j=1}^N P_{ij} V_j = \frac{\sum_{j=1}^N f_{ij} V_j}{\ell_i}$$

我们的目标是：在**不知道全局** m_i 和 ℓ_i 的情况下，通过分块逐步计算，最终得到完全相同的 O_i 。

2. 分块计算的递推公式推导

假设我们将序列分成 T 个块（为简化，我们固定一个 i ，只讨论一个查询向量）。设第 t 个块包含索引集合 B_t 。

2.1 关键变量定义（对第 i 个查询）

处理到第 t 个块时，我们维护三个累积状态：

- $m_i^{(t)}$ ：当前已处理块中遇到的最大分数值
- $\ell_i^{(t)}$ ：根据当前最大值 $m_i^{(t)}$ 调整后的指数部分和

3. $O_i^{(t)}$: 根据当前最大值 $m_i^{(t)}$ 调整后的未归一化输出累加值

初始化: $m_i^{(0)} = -\infty$, $\ell_i^{(0)} = 0$, $O_i^{(0)} = \mathbf{0}$ 。

2.2 处理第 t 个块的过程

当我们处理第 t 个块 B_t 时:

1. 计算块内分数: s_{ij} for $j \in B_t$
2. 找到块内最大值: $m_{i,B_t} = \max_{j \in B_t} s_{ij}$
3. 计算块内指数 (使用块内最大值): $f_{ij}^{(B_t)} = \exp(s_{ij} - m_{i,B_t})$ for $j \in B_t$
4. 计算块内指数和: $\ell_{i,B_t} = \sum_{j \in B_t} f_{ij}^{(B_t)}$
5. 计算块内加权和: $\tilde{O}_{i,B_t} = \sum_{j \in B_t} f_{ij}^{(B_t)} V_j$

现在, 我们有两个不同的"最大值":

- 旧全局最大值 $m_i^{(t-1)}$ (来自前 $t-1$ 块)
- 新块最大值 m_{i,B_t}

真正的全局最大值 (在处理了前 t 块后) 是:

$$m_i^{(t)} = \max(m_i^{(t-1)}, m_{i,B_t})$$

2.3 核心: 重新缩放 (Rescaling)

我们需要将所有之前的数据 (基于旧最大值计算的) 和新块的数据 (基于新块最大值计算的) 统一到新的全局最大值 $m_i^{(t)}$ 的尺度下。

重新缩放公式推导:

旧累加值 $\ell_i^{(t-1)}$ 是基于 $m_i^{(t-1)}$ 计算的:

$$\ell_i^{(t-1)} = \sum_{j \in B_1 \cup \dots \cup B_{t-1}} \exp(s_{ij} - m_i^{(t-1)})$$

当我们想将其转换到新尺度 $m_i^{(t)}$ 时:

$$\exp(s_{ij} - m_i^{(t)}) = \exp(s_{ij} - m_i^{(t-1)}) \cdot \exp(m_i^{(t-1)} - m_i^{(t)})$$

因此:

$$\sum_{j \in \text{old}} \exp(s_{ij} - m_i^{(t)}) = \ell_i^{(t-1)} \cdot \exp(m_i^{(t-1)} - m_i^{(t)})$$

类似地，新块数据 $f_{ij}^{(B_t)}$ 是基于 m_{i,B_t} 计算的，转换为新尺度：

$$\exp(s_{ij} - m_i^{(t)}) = \exp(s_{ij} - m_{i,B_t}) \cdot \exp(m_{i,B_t} - m_i^{(t)}) = f_{ij}^{(B_t)} \cdot \exp(m_{i,B_t} - m_i^{(t)})$$

因此：

$$\sum_{j \in B_t} \exp(s_{ij} - m_i^{(t)}) = \ell_{i,B_t} \cdot \exp(m_{i,B_t} - m_i^{(t)})$$

2.4 状态更新公式

指数和更新：

$$\ell_i^{(t)} = \underbrace{\ell_i^{(t-1)} \cdot \exp(m_i^{(t-1)} - m_i^{(t)})}_{\text{旧数据重缩放}} + \underbrace{\ell_{i,B_t} \cdot \exp(m_{i,B_t} - m_i^{(t)})}_{\text{新块数据重缩放}}$$

输出向量更新：

实际上， $O_i^{(t-1)}$ 存储的是未归一化的累加值，且是相对于当前最大值 $m_i^{(t-1)}$ 的：

$$O_i^{(t-1)} = \sum_{j \in B_1 \cup \dots \cup B_{t-1}} \exp(s_{ij} - m_i^{(t-1)}) V_j$$

将其转换到新尺度 $m_i^{(t)}$ ：

$$\sum_{j \in \text{old}} \exp(s_{ij} - m_i^{(t)}) V_j = O_i^{(t-1)} \cdot \exp(m_i^{(t-1)} - m_i^{(t)})$$

新块的未归一化累加值（基于块最大值）：

$$\tilde{O}_{i,B_t} = \sum_{j \in B_t} \exp(s_{ij} - m_{i,B_t}) V_j$$

转换到新尺度：

$$\sum_{j \in B_t} \exp(s_{ij} - m_i^{(t)}) V_j = \tilde{O}_{i,B_t} \cdot \exp(m_{i,B_t} - m_i^{(t)})$$

因此，输出更新公式：

$$O_i^{(t)} = \underbrace{O_i^{(t-1)} \cdot \exp(m_i^{(t-1)} - m_i^{(t)})}_{\text{旧输出重缩放}} + \underbrace{\tilde{O}_{i,B_t} \cdot \exp(m_{i,B_t} - m_i^{(t)})}_{\text{新块输出重缩放}}$$

3. 最终归一化与等效性证明

3.1 处理完所有块后

在处理完所有 T 个块后，我们得到：

- 全局最大值 $m_i^{(T)} = \max_{1 \leq j \leq N} s_{ij}$ (这正好是 m_i)
- 全局指数和 $\ell_i^{(T)} = \sum_{j=1}^N \exp(s_{ij} - m_i^{(T)}) = \sum_{j=1}^N \exp(s_{ij} - m_i)$ (这正好是 ℓ_i)
- 未归一化的输出累加值 $O_i^{(T)} = \sum_{j=1}^N \exp(s_{ij} - m_i) V_j$

3.2 最终输出

最终的归一化输出：

$$O_i = \frac{O_i^{(T)}}{\ell_i^{(T)}}$$

这正是标准Softmax Attention的输出公式：

$$O_i = \frac{\sum_{j=1}^N \exp(s_{ij} - m_i) V_j}{\sum_{j=1}^N \exp(s_{ij} - m_i)}$$

3.3 等效性证明总结

归纳法证明：

- **基础**：处理0个块时，状态与空集上的定义一致。
- **归纳假设**：假设处理完前 $t - 1$ 个块后，状态 $(m_i^{(t-1)}, \ell_i^{(t-1)}, O_i^{(t-1)})$ 正确地代表了已处理数据（基于当前最大值 $m_i^{(t-1)}$ 的指数尺度）的累积。
- **归纳步骤**：通过上述重新缩放公式，我们证明了在合并新块后，新的状态 $(m_i^{(t)}, \ell_i^{(t)}, O_i^{(t)})$ 正确地代表了所有已处理数据（基于新的全局最大值 $m_i^{(t)}$ 的指数尺度）的累积。
- **结论**：处理完所有块后，我们得到了与一次性计算完全相同的全局最大值 m_i 、指数和 ℓ_i 和未归一化输出累加值 $O_i^{(T)}$ 。归一化后得到精确的 O_i 。

4. 关键洞察

1. **分块计算不是近似**：每一步的重新缩放是精确的数学恒等式变换，没有引入任何误差。
2. **数值稳定性**：每个块内部使用自己的局部最大值计算指数，避免了当分数很大时指数溢出的问题。全局最大值的逐步更新确保了数值稳定性与一次性计算使用全局最大值时相同。
3. **在线算法**：这是一个典型的"在线算法"或"流式算法"，可以在不知道完整数据的情况下，逐步更新统计量（最大值、和、加权和）。
4. **空间换时间的逆转**：传统算法需要 $O(N^2)$ 中间存储空间来获得 $O(N^2 d)$ 计算时间。FlashAttention 通过重计算（在反向传播中）用大约两倍的计算量，换取了巨大的内存节省（从 $O(N^2)$ 到 $O(N)$ 的中间存储）。

5. 一个极小化的数值例子

假设 $N = 3$ ，分数 $s = [2.0, 1.0, 3.0]$ ， $V = [v_1, v_2, v_3]$ 。分两块： $B_1 = \{1, 2\}$ ， $B_2 = \{3\}$ 。

一次性计算：

- $m = 3.0$
- $f = [e^{-1}, e^{-2}, e^0] = [0.3679, 0.1353, 1.0]$
- $\ell = 1.5032$
- $O = (0.3679v_1 + 0.1353v_2 + 1.0v_3)/1.5032$

分块计算：

- **块1**： $m_{B_1} = 2.0$ ， $f_{B_1} = [e^0, e^{-1}] = [1.0, 0.3679]$ ， $\ell_{B_1} = 1.3679$ ， $\tilde{O}_{B_1} = 1.0v_1 + 0.3679v_2$
状态： $m^{(1)} = 2.0$ ， $\ell^{(1)} = 1.3679$ ， $O^{(1)} = 1.0v_1 + 0.3679v_2$
- **块2**： $m_{B_2} = 3.0$ ， $f_{B_2} = [e^0] = [1.0]$ ， $\ell_{B_2} = 1.0$ ， $\tilde{O}_{B_2} = 1.0v_3$
新全局最大值 $m^{(2)} = \max(2.0, 3.0) = 3.0$
重缩放因子： $\exp(2.0 - 3.0) = e^{-1} \approx 0.3679$ ， $\exp(3.0 - 3.0) = 1.0$

$$\ell^{(2)} = 1.3679 \times 0.3679 + 1.0 \times 1.0 = 0.5032 + 1.0 = 1.5032$$

$$O^{(2)} = (1.0v_1 + 0.3679v_2) \times 0.3679 + 1.0v_3 \times 1.0 = 0.3679v_1 + 0.1353v_2 + 1.0v_3$$

- **归一化**： $O = O^{(2)}/\ell^{(2)}$ ，与一次性计算结果完全相同。

这个推导展示了FlashAttention的分块计算在数学上是**严格等价**于标准注意力计算的，这是它作为一种**精确算法**而非近似方法的根本原因。